

Matematički fakultet
Beograd

Graph neural network for link prediction

Projekat iz predmeta
racunarska inteligencija

Bogdan Delic 36/2020
Zarija Trtovic 39/2020

Beograd, 2026.

Apstrakt

U ovom radu istražujemo primenu Graph Neural Networks (GNN) za zadatak predikcije veza (link prediction) u grafovima. Implementirana su i evaluirana dva modela zasnovana na deep learning-u — Graph Autoencoder (GAE) i Variational Graph Autoencoder (VGAE) — kao i klasična heuristička metoda Common Neighbors koja služi kao osnovna linija poredjenja (baseline). Eksperimenti su sprovedeni na standardnim benchmark skupovima podataka Cora i CiteSeer iz PyTorch Geometric biblioteke. Modeli su vrednovani pomoću metrika AUC (Area Under the ROC Curve) i AP (Average Precision). GAE model postigao je AUC od 0.8964 na Cora skupu, dok je VGAE dostigao AUC od 0.8894 na istom skupu. Common Neighbors baseline postigao je AUC od 0.6930 na Cora i 0.6714 na CiteSeer skupu, što potvrđuje superiornost pristupa zasnovanih na deep learning-u. Kroz eksperimente sa različitim hiperparametrima pokazano je da veće dimenzije embeddinga (hidden=128, out=64) generalno daju bolje rezultate. Vizualizacija embeddinga pomoću t-SNE algoritma ilustruje sposobnost modela da naučene reprezentacije organizuje prema tematskim kategorijama čvorova.

Ključne reci: graph neural network, link prediction, graph autoencoder, variational autoencoder, embedding, GCN, Cora, CiteSeer

1. Uvod

1.1 Motivacija

Grafovi predstavljaju jedan od najmoćnijih matematičkih alata za modelovanje složenih sistema koji se sastoje od entiteta i veza između njih. U savremenom digitalnom svetu, grafovske strukture su sveprisutne — od društvenih mreža i naučnih citata, do bioloških mreža proteina i finansijskih transakcija. Analiza takvih struktura postala je ključna oblast masinskog učenja.

Tradicionalne metode masinskog učenja nisu bile prilagođene radu sa grafovskim podacima, jer podrazumevaju ravne (tabelarne) strukture podataka. Pojava Graph Neural Networks (GNN) označila je prekretnicu — ovi modeli direktno obrađuju grafovsku strukturu i sposobni su da uče reprezentacije čvorova uzimajući u obzir njihovo lokalno okruženje (susedstvo).

1.2 Problem predikcije veza

Predikcija veza (link prediction) jedan je od centralnih problema analize grafova. Cilj je predvideti koje veze između čvorova postoje, ali nisu zabeležene, ili koje veze će se pojaviti u budućnosti. Formalno, dat je graf $G = (V, E)$ gde V označava skup čvorova, a E skup poznatih grana. Zadatak je oceniti verovatnoću postojanja grane (u, v) za par čvorova u, v koji nije u skupu E .

Ovaj problem ima direktnu praktičnu primenu u brojnim domenima: preporuka prijatelja na društvenim mrežama, predviđanje interakcija protein-lek u bioinformatiči, otkrivanje potencijalnih saradnji između naučnika, kao i otkrivanje skrivenih veza u finansijskim mrežama radi detekcije prevara.

1.3 Ciljevi rada

Ovaj rad ima sledeće ciljeve:

1. Implementacija Graph Autoencoder (GAE) modela zasnovanog na GCN slojevima za zadatak predikcije veza.
2. Implementacija Variational Graph Autoencoder (VGAE) modela koji uvodi probabilistički okvir kroz varijacioni autoenkoder.
3. Evaluacija i poredjenje oba modela sa Common Neighbors heurističkim baseline-om na skupovima Cora i CiteSeer.
4. Analiza uticaja hiperparametara (velicina skrivenih slojeva, stopa učenja) na performanse modela.
5. Vizualizacija naučenih embeddinga pomoću t-SNE algoritma i analiza grešaka modela.

1.4 Struktura rada

Rad je organizovan na sledeći način. U Glavi 2 data je teorijska osnova koja pokriva osnove teorije grafova, GNN arhitektura, kao i matematički formalizmi GAE i VGAE modela. Glava 3 opisuje korišćene skupove podataka i proces njihove predobrade. Glava 4 detaljno opisuje

implementaciju modela, funkcije gubitka i trening proceduru. Glava 5 prikazuje eksperimentalne rezultate i analize. Glava 6 sadrži diskusiju rezultata, a Glava 7 zaključak.

1.5 Znacaj i primene predikcije veza

Predikcija veza ima širok spektar primena u realnom svetu. U oblasti preporuka, koristi se za predlaganje novih prijatelja na platformama poput LinkedIn-a ili Facebook-a. U bioinformatiči, pomaze u otkrivanju novih interakcija između gena i proteina, što može ubrzati razvoj novih lekova. U e-commerce sistemima, koristi se za preporuku proizvoda. Posebno je vredna u analizi naučnih mreža citata, gde može predvideti koje će radove naučnici citirati u budućnosti, pomazući u otkrivanju relevantnih istraživanja.

2. Teorijska osnova

2.1 Grafovi i reprezentacija grafova

Graf $G = (V, E)$ definiše se kao par skupova, gde $V = \{v_1, v_2, \dots, v_n\}$ predstavlja skup cvorova, a $E \subseteq V \times V$ skup grana. U neusmerenim grafovima, grana $(u, v) \in E$ ekvivalentna je grani (v, u) , dok su u usmerenim grafovima ove dve grane različite.

Osnovna reprezentacija grafa u racunarskom okruženju je matrica susedstva $A \in \{0,1\}^{n \times n}$, gde $A_{ij} = 1$ ako postoji grana između cvorova i i j , a 0 inace. Pored topološke strukture, svaki cvor može imati pridružen vektor atributa (features) $x_i \in \mathbb{R}^d$, koji se skupno zapisuje kao matrica $X \in \mathbb{R}^{n \times d}$.

U kontekstu ovog rada, grafovi predstavljaju mreže naučnih publikacija gde cvorovi odgovaraju naučnim radovima, grane odgovaraju vezama citiranja između radova, a atributi cvorova su bag-of-words vektori koji opisuju sadržaj rada.

2.2 Predikcija veza

Formalno, problem predikcije veza definiše se na sledeći način: dat je parcijalno observiran graf $G = (V, E_{\text{train}})$, gde $E_{\text{train}} \subset E^*$ predstavlja podskup svih stvarnih grana E^* . Cilj je naučiti funkciju ocenjivanja $f : V \times V \rightarrow \mathbb{R}$ koja dodeljuje visoke skorove parovima cvorova koji su zapravo povezani, a niske skorove parovima koji nisu.

Evaluacija modela vrši se nad test skupom grana $E_{\text{test}} = E^* \setminus E_{\text{train}}$, zajedno sa negativnim primerima — nasumično odabranim parovima cvorova za koje grana ne postoji. Standardne metrike evaluacije su AUC (Area Under the ROC Curve) i AP (Average Precision).

2.3 Graph Neural Networks (GNN)

Graph Neural Networks su klasa dubokih neuronskih mreža dizajniranih za rad sa grafovskim podacima. Osnovna ideja GNN-a je message passing mehanizam: svaki cvor agregira informacije od svojih suseda i azurira sopstvenu reprezentaciju. Formalno, za l -ti sloj GNN-a:

$$h_v^{(l)} = \text{UPDATE}(h_v^{(l-1)}, \text{AGGREGATE}(\{h_u^{(l-1)} : u \in N(v)\}))$$

gde $N(v)$ označava skup suseda cvora v , a funkcije AGGREGATE i UPDATE su naučene transformacije. Nakon L slojeva agregacije, svaki cvor ima embedding koji koduje informacije iz svog L -hop susedstva.

2.4 Graph Convolutional Network (GCN)

Graph Convolutional Network (Kipf i Welling, 2017) jedan je od najuticajnijih GNN modela. GCN propagira informacije kroz graf primenjujući konvolucionalne transformacije u spektralnom domenu. Azuriranje u GCN sloju definisano je kao:

$$H^{(l+1)} = \sigma(D^{-1/2} \tilde{A} D^{-1/2} H^{(l)} W^{(l)})$$

gde je $\tilde{A} = A + I$ normalizovana matrica susedstva sa self-loop vezama, D je dijagonalna matrica stepena, $H^{(l)}$ je matrica reprezentacija u l -tom sloju, $W^{(l)}$ je matrica tezina, a σ je aktivaciona funkcija. GCNConv sloj iz PyTorch Geometric biblioteke korišćen je u ovoj implementaciji.

2.5 Embedding reprezentacije cvorova

Embedding cvora je niskodimenzionalni vektorski prikaz koji koduje strukturne i atributivne informacije o cvoru. Cilj učenja embeddinga je da se slicni cvorovi (koji su blizu u grafu ili imaju slične attribute) preslikaju u bliske vektore u embedding prostoru.

U ovom radu, GAE i VGAE modeli uče embedding matricu $Z \in \mathbb{R}^{n \times d}$ gde je d dimenzija embeddinga (32 u osnovnoj konfiguraciji). Predikcija postojanja grane između cvorova i i j vrši se unutrašnjim proizvodom njihovih embeddinga: $\text{score}(i, j) = \sigma(z_i^T z_j)$.

2.6 Graph Autoencoder (GAE)

Graph Autoencoder (Kipf i Welling, 2016) je model koji uči embedding reprezentacije cvorova kroz enkoder-dekoder arhitekturu primenjenu na grafovima. Enkoder je dvoslojna GCN mreža koja mapira ulazne attribute X i topologiju A u embedding prostor Z :

$$Z = GCN(X, A) = \tilde{A} \text{ReLU}(\tilde{A} X W^{(0)}) W^{(1)}$$

Dekoder rekonstruiše matricu susedstva koristeći unutrašnji proizvod embeddinga: $\hat{A} = \sigma(Z Z^T)$. Trening se vrši minimizacijom binarne unakrsne entropije između prediktovanih i stvarnih grana.

2.7 Variational Graph Autoencoder (VGAE)

Variational Graph Autoencoder (Kipf i Welling, 2016) proširuje GAE uvođenjem probabilističkog okvira inspirisanog Variational Autoencoderima (VAE). Umesto da direktno uči embedding Z , VGAE modeluje distribuciju posteriornog verovatnoće $q(Z|X, A) = \prod_i q(z_i|X, A)$, gde je $q(z_i|X, A) = N(z_i|\mu_i, \text{diag}(\sigma_i^2))$.

Enkoder VGAE-a ima tri GCN sloja: jedan zajednicki skriveni sloj, i dva paralelna izlazna sloja koji uče μ (srednje vrednosti) i $\log \sigma$ (logaritme standardnih devijacija) respektivno. Tokom treninga, z se uzorkuje koristeći reparametrizacijski trik: $z = \mu + \epsilon * \exp(\log \sigma)$, gde je $\epsilon \sim N(0, I)$.

Funkcija gubitka VGAE-a kombinuje rekonstrukcioni gubitak i KL divergenciju kao regularizacioni termin: $L = L_{\text{BCE}} + \beta \cdot D_{\text{KL}}$. U ovoj implementaciji, $\beta = 0.005$. KL divergencija između naucene distribucije $N(\mu, \sigma^2)$ i standardne normalne $N(0, I)$ iznosi:

$$D_{\text{KL}} = -0.5 \cdot \text{mean}(1 + 2 \log \sigma - \mu^2 - \exp(2 \log \sigma))$$

2.8 Common Neighbors heuristika

Common Neighbors (CN) je jedna od najstarijih i najjednostavnijih heuristickih metoda za predikciju veza, koja ne zahteva nikakav proces učenja. Score između para cvorova (u, v) definiše se kao broj zajednickih suseda:

$$\text{score}(u, v) = |N(u) \cap N(v)|$$

Ideja je zasnovana na principu da je veca verovatnoca da dva cvora budu povezana ako imaju mnogo zajednickih suseda. Ova metoda služi kao baseline u ovom radu, i njena relativna slabost u poredjenju sa GNN modelima ilustruje prednost pristupa koji uče iz podataka.

3. Korišćeni skupovi podataka

Za evaluaciju predloženih modela korišćena su dva standardna benchmark skupa podataka iz domena naučnih citata, dostupna kroz PyTorch Geometric biblioteku. Oba skupa su deo Planetoid kolekcije i široko su korišćena u literaturi za evaluaciju algoritama nad grafovima.



3.1 Cora skup podataka

Cora je mreža mašinskog učenja koja se sastoji od naučnih radova kategorizovanih u 7 klasa: Case Based, Genetic Algorithms, Neural Networks, Probabilistic Methods, Reinforcement Learning, Rule Learning i Theory. Grane između čvorova predstavljaju citiranja između radova.

Karakteristika	Vrednost
Broj čvorova	2 708
Broj grana	10 556
Broj klasa	7
Dimenzija feature vektora	1 433
Prosečan stepen čvora	3.90
Maksimalni stepen	168
Minimalni stepen	1
Trening grana	8 976
Validacione grane	263
Test grane	527

Tabela 3.1: Karakteristike Cora skupa podataka

Feature vektor svakog čvora je bag-of-words reprezentacija teksta rada, normalizovana sa NormalizeFeatures transformacijom. Matrica atributa X ima dimenziju 2708×1433 .




3.2 CiteSeer skup podataka

CiteSeer je mreza naucnih publikacija iz oblasti racunarskih nauka, kategorizovana u 6 klasa: Agents, AI, DB, IR, ML i HCI. Kao i Cora, grane predstavljaju veze citiranja izmedju radova. CiteSeer ima bogatiji feature prostor (3703 dimenzije) ali nešto manji prosečan stepen cvorova u poredjenju sa Cora skupom.


Karakteristika	Vrednost
Broj cvorova	3 327
Broj grana	9 104
Broj klasa	6
Dimenzija feature vektora	3 703

Prosecan stepen cvora	2.74
Maksimalni stepen	99
Minimalni stepen	0
Trening grana	7 740
Validacione grane	227
Test grane	455

Tabela 3.2: Karakteristike CiteSeer skupa podataka



Vizualizacija CiteSeer grafa — prvih 200 cvorova



Distribucija stepena cvorova u CiteSeer grafu

3.3 Predobrada podataka

Predobrada podataka obuhvata nekoliko koraka koji su neophodni pre treninga modela. Feature vektori cvorova normalizovani su primenom NormalizeFeatures transformacije iz

PyTorch Geometric biblioteke, cime se svaki red matrice X normalizuje na L1 normu. Ovo osigurava numericku stabilnost tokom treninga.

Grane su podeljene na trening, validacioni i test skup korišćenjem `train_test_split_edges` funkcije. Skup grana delio se u odnosu 85%/5%/10% za trening, validaciju i test respektivno. Za svaku pozitivnu granu u test i validacionom skupu, generisan je isti broj negativnih primera (parovi cvorova bez grane) korišćenjem `negative_sampling` funkcije, što obezbedjuje balansiran evaluacioni skup.

4. Implementacija modela

4.1 Implementacija GAE modela

GAE model implementiran je kao PyTorch nn.Module klasa sa enkoder-dekoder arhitekturom. Enkoder se sastoji od dva GCNConv sloja: prvi sloj mapira ulaz dimenzije 1433 (Cora) na skriveni prostor dimenzije 64, a drugi sloj preslikava na embedding prostor dimenzije 32. ReLU aktivacija primenjena je izmedju slojeva.

Dekodovanje se vrši unutrašnjim (skalarnim) proizvodom embeddinga para cvorova: $\text{score}(i, j) = \mathbf{z}_i^T \cdot \mathbf{z}_j$. Ovaj pristup je efikasan jer ne zahteva dodatne parametre i prirodno odrazava sličnost izmedju vektora.

Arhitektura GAE modela:

GCNConv(in=1433, out=64) → ReLU → GCNConv(in=64, out=32) → Dekoder (unutrašnji proizvod)

Ključni delovi implementacije:

Metoda encode prima matricu atributa X i indekse grana edge_index, propušta ih kroz oba GCN sloja i vraća embedding matricu Z. Metoda decode prima embedding matricu i indekse grana za koje se predviđa, a vraća skor za svaki par cvorova — bez primene sigmoid aktivacije, jer se ona implicitno uključuje u BCEWithLogitsLoss funkciju gubitka, čime se poboljšava numericka stabilnost.

4.2 Implementacija VGAE modela

VGAE model proširuje GAE arhitekturu varijacionim okvirom. Enkoder ima isti prvi GCN sloj kao GAE, ali umesto jednog izlaznog sloja, ima dva paralelna GCN sloja: conv_mu koji uči srednje vrednosti μ i conv_logstd koji uči logaritme standardnih devijacija $\log \sigma$.

Tokom treninga (model.train() mod), koristi se reparametrizacijski trik: $\epsilon \sim N(0, I)$ uzorkuje se, a embedding se računa kao $\mathbf{z} = \mu + \epsilon \cdot \exp(\log \sigma)$. Tokom evaluacije (model.eval() mod), koristi se samo μ za deterministički, stabilniji izlaz. Vrednosti $\log \sigma$ ograničene su na maksimum 10 radi numeričke stabilnosti.

Arhitektura VGAE modela:

GCNConv(in=1433, out=64) → ReLU → [conv_mu(64, 32) || conv_logstd(64, 32)] → Uzorkovanje z → Dekoder

4.3 Funkcija gubitka

Za GAE model koristi se binarna unakrsna entropija (BCEWithLogitsLoss) izmedju prediktovanih skorova i stvarnih labela (1 za pozitivne grane, 0 za negativne):

$$L_{GAE} = -[y \cdot \log(\sigma(s)) + (1-y) \cdot \log(1 - \sigma(s))]$$

Za VGAE model, ukupna funkcija gubitka je zbir rekonstrukcionog gubitka i KL regularizacionog termina:

$$L_{VGAE} = L_{BCE} + 0.005 \cdot D_{KL}$$

Koeficijent $\beta = 0.005$ pazljivo je odabran eksperimentalno kako bi se KL regularizacija uravnotežila sa rekonstrukcionim gubitkom — premali koeficijent cini VGAE ekvivalentnim GAE-u, dok preveliki koeficijent previše ograničava latentni prostor.

4.4 Trening procedura

Oba modela trenirana su korišćenjem Adam optimizatora uglavnom sa stopom učenja $lr = 0.01$. GAE je treniran 200 epoha, dok je VGAE treniran 300 epoha zbog sporijeg konvergiranja usled probabilističke prirode modela. Svake epohe, za svaku pozitivnu trening granu generišan je isti broj negativnih primera nasumičnim uzorkovanjem parova cvorova bez grane.

Korišćena je early stopping strategija zasnovana na validacionom AUC-u — cuvan je model sa najboljim validacionim AUC-om tokom celog treninga (`torch.save`), a na kraju se taj model učitava i koristi za finalnu evaluaciju na test skupu.

Reproduktivnost eksperimenata obezbeđena je fiksiranjem random seed-a na vrednost 42 za PyTorch (`torch.manual_seed`) i NumPy (`np.random.seed`).

4.5 Evaluacione metrike

Performanse modela merene su dvema standardnim metrikama za zadatak predikcije veza:

AUC (Area Under the ROC Curve) — meri sposobnost modela da razlikuje pozitivne od negativnih primera. $AUC = 1.0$ označava savršenu predikciju, dok $AUC = 0.5$ odgovara nasumičnom pogađanju. AUC je robustan na neravnomjernu distribuciju klasa.

AP (Average Precision) — izračunava površinu ispod precision-recall krive, uzimajući u obzir preciznost pri različitim nivoima odziva. AP je posebno informativna metrika kada su klase neravnomerno zastupljene.


5. Eksperimenti i rezultati

5.1 Eksperimenti sa hiperparametrima

Sprovedeni su sistematski eksperimenti sa cetiri konfiguracije hiperparametara za oba modela na oba skupa podataka. Ispitivane su dimenzije skrivenih slojeva i stope ucenja, dok su ostali hiperparametri ostali fiksni.

Skriveni sloj	Embedding dim.	Stopa ucenja	Epohe	AUC	AP
128	64	0.010	200	0.9200	0.9296
64	32	0.010	200	0.9132	0.9166
32	16	0.010	200	0.9060	0.9113
64	32	0.001	300	0.8466	0.8423


Tabela 5.1: GAE — eksperimenti sa hiperparametrima (Cora)



GAE — poredjenje hiperparametara (Cora)

Skriveni sloj	Embedding dim.	Stopa ucenja	Epohe	AUC	AP
128	64	0.010	200	0.9133	0.9240
64	32	0.010	200	0.8895	0.8941
32	16	0.010	200	0.8559	0.8561
64	32	0.001	300	0.6572	0.7020

Tabela 5.2: VGAE — eksperimenti sa hiperparametrima (Cora)



Ključni zaključci iz eksperimenata sa hiperparametrima: konfiguracija sa hidden=128 i out=64 konsistentno daje beste rezultate za oba modela. Manja stopa učenja $lr=0.001$ značajno degradira performanse, posebno za VGAE (pad AUC-a na 0.657), što ukazuje na to da model treba viši gradijent signal za pravilno učenje varijacionog koda.

5.2 Rezultati GAE modela

GAE model pokazao je odlične performanse na oba skupa podataka. Na Cora skupu, model je dostigao stabilnu konvergenciju oko 100-te epohe sa finalnim test AUC-om od 0.8964 i AP-om od 0.9036. Konvergencija je bila brza i monotona, što ukazuje na dobro postavljen problem optimizacije.

Dataset	Test AUC	Test AP	Best Val. AUC	Epohe do konv.
Cora	0.8964	0.9036	0.9061 (ep. 140)	~100
CiteSeer	0.8824	0.8860	0.9111 (ep. 110)	~110

Tabela 5.3: GAE finalni rezultati

5.3 Rezultati VGAE modela

VGAE model zahtevao je veći broj epoha za konvergenciju (300 epoha), što je očekivano s obzirom na kompleksniju probabilističku prirodu modela. Tokom prvih 50-tak epoha, model prolazi kroz fazu 'zagrevanja' u kojoj KL regularizacija dominira i usporava učenje. Nakon te faze, model ubrzano konvergira.

Dataset	Test AUC	Test AP	Best Val. AUC	Epohe do konv.
Cora	0.8894	0.8970	0.9010 (ep. 260)	~190
CiteSeer	0.8986	0.8976	0.9087 (ep. 290)	~250

Tabela 5.4: VGAE finalni rezultati

5.4 Common Neighbors baseline

Common Neighbors heuristika implementirana je bez procesa učenja. Svaki cvor ima svoju listu suseda konstruisanu iz trening skupa grana. Za svaki par (u, v) , skor je jednak velicini preseka skupova suseda $N(u) \cap N(v)$. Analiza grešaka pokazala je da CN pravi greške kod cvorova koji su blisko tematski srodnih ali nemaju zajednickih suseda (lazni negativni sa $CN=0$) i kod cvorova koji dele susede ali nisu direktno povezani (lazni pozitivni).

Dataset	AUC	AP
Cora	0.6930	0.6891
CiteSeer	0.6714	0.6714

Tabela 5.5: Common Neighbors baseline rezultati

5.5 Poredjenje modela

Sledeca tabela prikazuje sveobuhvatno poredjenje svih modela i metoda na oba skupa podataka. GNN modeli jasno nadmašuju heuristicki pristup, dostizuci 20+ procentnih poena više AUC vrednosti.




Model	Cora AUC	Cora AP	CiteSeer AUC	CiteSeer AP
GAE	0.8964	0.9036	0.8824	0.8860
VGAE	0.8894	0.8970	0.8986	0.8976
Common Neighbors	0.6930	0.6891	0.6714	0.6714

Tabela 5.6: Sveobuhvatno poredjenje svih modela

Interesantno je da VGAE na CiteSeer skupu (0.8986) postize nešto bolje rezultate od GAE (0.8824), dok je na Cora skupu situacija obrnuta. Ovo sugeruje da probabilisticka regularizacija VGAE-a moze biti korisna za skupove podataka sa specficnim karakteristikama, kao što je retka matrica susedstva CiteSeer-a.

5.6 Vizualizacija embedidinga pomocu t-SNE

t-SNE (t-Distributed Stochastic Neighbor Embedding) korišćen je za vizualizaciju naucenih embeddinga u 2D prostoru. Primenjen je sa $n_components=2$, $perplexity=30$ i $random_state=42$. cvorovi su obojeni prema klasi kojoj pripadaju (7 klasa za Cora, 6 za CiteSeer).




Vizualizacije t-SNE jasno ilustruju da nauceni embeddings imaju znatno bolju klustersku strukturu u poredjenju sa originalnim feature-ima. cvorovi iste klase grupisani su blize zajedno u embedding prostoru, što potvrđuje da modeli uspešno uče semantički smislene reprezentacije koje odražavaju topološku strukturu grafa.

5.7 Krive ucenja


Krive treninga prate loss vrednost kroz epohe za oba modela. GAE pokazuje glatku, monotono opadajucu krivulju gubitka, dok VGAE ima karakteristicne oscilacije u ranim epohama usled stohastickog uzorkovanja iz latentnog prostora.




GAE — kriva trening gubitka (Cora)



GAE — validacioni AUC kroz epohe (Cora)



VGAE — kriva trening gubitka (Cora)



VGAE — validacioni AUC kroz epohe (Cora)

5.8 Analiza grešaka

Sprovedena je detaljna analiza grešaka Common Neighbors metode na Cora skupu podataka radi boljeg razumevanja ograničenja heuristickog pristupa. Analizom laznih pozitivna (false positives) i laznih negativna (false negatives) pri pragu od 1 zajednicki sused, dobijeni su sledeci uvidi:

Lazni pozitivni (False Positives): Parovi cvorova koji dele zajednicke susede ali zapravo nisu direktno povezani. Najizrazitiji primer je par (137, 2144) sa $CN=3$ — ovi cvorovi imaju 3 zajednicka suseda što sugerise potencijalnu vezu, ali ona nije registrovana u skupu podataka.

Lazni negativni (False Negatives): Stvarne veze izmedju cvorova koje CN ne uspeva da detektuje jer ti cvorovi nemaju zajednickih suseda ($CN=0$). Ovo je fundamentalno ograničenje lokalne heuristike — ne moze da predvidi veze izmedju cvorova koji se nalaze u razlicitim delovima grafa.

6. Diskusija

Rezultati eksperimenata potvrđuju superiornost pristupa zasnovanih na dubokom učenju nad klasičnim heurističkim metodama za zadatak predikcije veza. GNN modeli (GAE i VGAE) nadmašuju Common Neighbors baseline za više od 20 procentnih poena u smislu AUC metrike na oba skupa podataka.

Poredjenje GAE i VGAE modela pokazuje da njihove performanse nisu konzistentno superiorne jedna drugoj — na Cora skupu GAE ima blagu prednost, dok na CiteSeer skupu VGAE postize bolje rezultate. Ovo ukazuje na to da probabilistička regularizacija VGAE-a nije uvek korisna i da njen benefit zavisi od karakteristika konkretnog skupa podataka. Redkija mreža CiteSeer-a (prosecan stepen 2.74 vs 3.90 za Cora) cini se da pogoduje varijacionom pristupu.

Eksperimenti sa hiperparametrima pokazali su da je velicina embeddinga vaznija od stope učenja. Konfiguracija hidden=128, out=64 konzistentno daje bolje rezultate. Niza stopa učenja $lr=0.001$ posebno negativno utice na VGAE, jer model nije u stanju da adekvatno 'pobedi' KL regularizaciju u kratkom broju epoha.

t-SNE vizualizacije embeddinga pružaju kvalitativni uvid u kvalitet naucenih reprezentacija. Nauceni embeddingi pokazuju znatno bolju klasterizaciju prema klasi cvora u poredjenju sa originalnim bag-of-words feature-ima, što potvrđuje da modeli uspešno kombinuju topološke informacije grafa sa atributivnim informacijama cvorova.

Analiza grešaka Common Neighbors metode otkriva fundamentalno ogracenje lokalnih heuristika: ne mogu da predvide veze izmedju cvorova koji su semanticki srodni ali topološki udaljeni. GNN modeli prevazilaze ovo ogracenje zahvaljujuci multi-hop propagaciji informacija kroz GCN slojeve koji omogucavaju da svaki cvor 'vidi' dalje od svog neposrednog susedstva.

Jedno od ogracenja ovog rada je korišćenje relativno malog broja GCN slojeva (2 sloja) što ogranicava doseg informacija na 2-hop susedstvo. Dublje arhitekture bi potencijalno mogle poboljšati performanse, mada problem 'oversmoothing'-a moze biti problem za dublje GNN mreže.

7. Zaključak

U ovom radu implementirani su i evaluirani Graph Autoencoder (GAE) i Variational Graph Autoencoder (VGAE) modeli za zadatak predikcije veza u grafovima. Eksperimenti sprovedeni na Cora i CiteSeer skupovima podataka pokazali su da GNN modeli znatno nadmašuju heuristicku Common Neighbors metodu, postizuci AUC vrednosti oko 0.89-0.90 u poredjenju sa 0.67-0.69 za heuricki pristup.

GAE model postigao je AUC od 0.8964 na Cora i 0.8824 na CiteSeer skupu. VGAE je postigao AUC od 0.8894 na Cora i 0.8986 na CiteSeer skupu. Oba modela pokazala su dobru sposobnost generalizacije i stabilnu konvergenciju tokom treninga.

Eksperimenti sa hiperparametrima pokazali su da vece dimenzije embedding prostora (hidden=128, out=64) generalno daju bolje rezultate, dok je stopa ucenja od 0.01 pokazala se optimalnom za oba modela. Vizualizacija embedidinga pomocu t-SNE algoritma potvrdila je da naucene reprezentacije imaju smislenu klastersku strukturu koja odrazava tematske kategorije naucnih radova.

Kao pravci buduceg istrazivanja mogu se navesti: primena naprednijih GNN arhitektura poput Graph Attention Networks (GAT) koji koriste mehanizam paznje za adaptivno ponderisanje suseda; ispitivanje induktivnih pristupa koji bi mogli raditi na novim, nevidjenim cvorovima; eksperimenti na vecim i raznovrsnijim skupovima podataka kao što je OGB (Open Graph Benchmark); kao i primena modela na konkretnim domenima poput preporuke sadrzaja ili bioinformatike.

8. Literatura

- [1] Kipf, T. N., & Welling, M. (2016). Variational graph auto-encoders. arXiv preprint arXiv:1611.07308.
- [2] Kipf, T. N., & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. In Proceedings of ICLR 2017.
- [3] Hamilton, W. L., Ying, R., & Leskovec, J. (2017). Representation learning on graphs: Methods and applications. IEEE Data Engineering Bulletin.
- [4] Liben-Nowell, D., & Kleinberg, J. (2007). The link-prediction problem for social networks. Journal of the American Society for Information Science and Technology, 58(7), 1019-1031.
- [5] Fey, M., & Lenssen, J. E. (2019). Fast graph representation learning with PyTorch Geometric. In ICLR Workshop on Representation Learning on Graphs and Manifolds.
- [6] Kingma, D. P., & Welling, M. (2013). Auto-encoding variational bayes. arXiv preprint arXiv:1312.6114.
- [7] Sen, P., Namata, G., Bilgic, M., Getoor, L., Gallagher, B., & Eliassi-Rad, T. (2008). Collective classification in network data. AI Magazine, 29(3), 93-106.
- [8] Van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. Journal of Machine Learning Research, 9(11).
- [9] Zhang, M., & Chen, Y. (2018). Link prediction based on graph neural networks. In Advances in Neural Information Processing Systems (NeurIPS).
- [10] Zhou, J., Cui, G., Hu, S., Zhang, Z., Yang, C., Liu, Z., ... & Sun, M. (2020). Graph neural networks: A review of methods and applications. AI Open, 1, 57-81.